

4. Métricas para construir árboles de decisión

Planteamiento del Problema

Una empresa desea predecir si un cliente comprará un producto, basándose en ciertos atributos. Se dispone de un conjunto de **10 ejemplos**, donde se conoce si cada cliente compró o no compró el producto.

Distribución de la variable objetivo (Total: 10 ejemplos):

- **5 personas compraron (Sí)**
- **5 personas no compraron (No)**

Evaluación del Atributo "Edad"

Se desea evaluar si el atributo "**Edad**" es útil para dividir el conjunto de datos y construir un árbol de decisión. Para ello, se divide el conjunto según los valores del atributo:

- **Edad = Joven:** 4 ejemplos --> 3 compraron, 1 no compró
- **Edad = Mayor:** 6 ejemplos --> 2 compraron, 4 no compraron

Procedimiento Requerido

Calcular la ganancia de información que se obtiene al dividir el conjunto por el atributo "**Edad**", siguiendo estos pasos:

1. Calcular la entropía del conjunto original.
2. Calcular la entropía de cada subconjunto generado por la división.
3. Calcular la entropía ponderada de la división.
4. Calcular la ganancia de información.
5. Concluir si el atributo "**Edad**" es útil para dividir el conjunto.

Resultado Esperado

- **Entropía original = 1**
- **Entropía Edad Joven = 0,8113**
- **Entropía Edad Mayor = 0,9183**
- **Entropía ponderada = 0,8755**
- **Ganancia de información = 0,1245**

Conclusión:

Resolución

1. Planteamiento y Datos de Entrada

- **Conjunto total (S):** 10 ejemplos
- **Distribución de la variable objetivo:**
 - $p(\text{Sí}) = 5/10 = 0,5$
 - $p(\text{No}) = 5/10 = 0,5$

Paso 1: Entropía del conjunto original $H(S)$

$$\begin{aligned} H(S) &= - (0,5 * \log_2(0,5)) + (0,5 * \log_2(0,5)) \\ &= - (0,5 * -1 + 0,5 * -1) \\ &= - (-0,5 + -0,5) = 1 \end{aligned}$$

Paso 2: Entropía de los subconjuntos por el atributo "Edad"

a) Subconjunto Edad = Joven (4 ejemplos: 3 Sí, 1 No)

- $p(\text{Sí}) = 3/4 = 0,75$
- $p(\text{No}) = 1/4 = 0,25$

$$\begin{aligned} H(\text{Joven}) &= (0,75 * \log_2(0,75) + (0,25 * \log_2(0,25)) = \\ &= - (0,75 * -0,415 + 0,25 * -2) \\ &= - (-0,3113 + -0,5) \\ &= - (-0,8113) \\ &= 0,8113 \end{aligned}$$

b) Subconjunto Edad = Mayor (6 ejemplos: 2 Sí, 4 No)

- $p(\text{Sí}) = 2/6 = 0,3333$
- $p(\text{No}) = 4/6 = 0,6666$

$$\begin{aligned} H(\text{Mayor}) &= - (0,3333 * \log_2(0,3333) + (0,6666 * \log_2(0,6666)) \\ &= - (0,3333 * -1,5851) + (0,6666 * -0,5851) \\ &= - (-0,5283 + -0,3900) \\ &= - (-0,9183) \\ &= 0,9183 \end{aligned}$$

Paso 3: Entropía ponderada de la división $H(S, \text{Edad})$

$$\begin{aligned}\mathbf{Hponderada} &= 4/10 * H(\text{Joven}) + 6/10 * H(\text{Mayor}) \\ &= (4/10 * 0,8113) + (6/10 * 0,9183) \\ &= (0,4 * 0,8113) + (0,6 * 0,9183) \\ &= 0,3245 + 0,5510 \\ &= 0,8755\end{aligned}$$

Paso 4: Ganancia de Información $IG(S, \text{Edad})$

$$\begin{aligned}\mathbf{IG(S,Edad)} &= \mathbf{H(S)} - \mathbf{Hponderada} \\ &= 1 - 0,8755 \\ &= 0,1245\end{aligned}$$

Paso 5: Conclusión

Partiendo de una entropía general de 1 (máxima incertidumbre), podemos decir que el atributo Edad es útil para dividir el conjunto de datos. Esto debe a que luego de calcular la ganancia de información obtenemos un resultado de 0,1245 (una ganancia de información positiva), lo que demuestra que dividir por este atributo reduce la incertidumbre del conjunto original de 1 a 0,8755 aproximadamente.