

5. Árbol de decisión

a) Construcción de un árbol de decisión

Una empresa de telecomunicaciones quiere predecir si un cliente aceptará una oferta de plan de datos móviles. Para ello, se dispone de un conjunto de datos con información de **10 clientes**, incluyendo los siguientes atributos:

- **Edad** (en años)
- **Nivel de uso mensual de datos** (en GB)
- **Tiene línea fija** (Sí / No)
- **Aceptó la oferta** (Sí / No)

Datos del Conjunto

ID	Edad	Uso de datos (GB)	Tiene línea fija	Aceptó oferta
1	24	2.5	No	No
2	38	6.0	Sí	Sí
3	29	3.0	No	No
4	45	8.0	Sí	Sí
5	52	7.5	Sí	Sí
6	33	4.0	No	No
7	41	5.5	Sí	Sí
8	27	2.0	No	No
9	36	6.5	Sí	Sí
10	31	3.5	No	No

Objetivo del Ejercicio

1. Calcular la entropía del conjunto original $H(S)$.
2. Evaluar la ganancia de información para los atributos:
 - a. **Edad** (agrupada en rangos: Joven ≤ 30 , Adulto 31 - 50, Mayor > 50)
 - b. **Tiene línea fija** (Sí / No)
 - c. **Uso de datos** (agrupado: Bajo $\leq 3GB$, Medio 3.1 - 6GB, Alto $> 6GB$)
3. Construir el árbol de decisión paso a paso.
4. Concluir cuál es el mejor atributo para comenzar el árbol y cómo se puede usar para predecir si un cliente aceptará la oferta.

Plantilla de Resultados

- **Entropía del conjunto original $H(S) = 1$**
- **Ganancia de Información - Edad = 0,449**
- **Ganancia de Información - Tiene línea fija = 1**
- **Ganancia de Información - Uso de datos = 0,6**
- **Mejor atributo para el nodo raíz = Tiene Línea Fija**

1. Entropía del Conjunto Original H(S)

- **Total de clientes** = 10 (Aceptan = 5, No Aceptan = 5)
 - $p_{Si} = 5/10 = 0,5$
 - $p_{No} = 5/10 = 0,5$

$$\begin{aligned} H(S) &= - (0,5 * \log_2(0,5)) + (0,5 * \log_2(0,5)) \\ &= - (0,5 * -1 + 0,5 * -1) \\ &= - (-0,5 + -0,5) \\ &= 1 \end{aligned}$$

2. Entropía y Ganancia de Información por Atributo

2.1 Atributo: Edad

Joven <= 30

ID {1,3,8}

Acepta: 0 / No Acepta: 3

$$\text{Acepta} = 0/3 = 0 \quad / \quad \text{No Acepta} = 3/3 = 1$$

$$\begin{aligned} H(S, \text{Joven}) &= -(0 * \log_2(0) + (1 * \log_2(1))) \\ &= -(0 + 1 * 0) \\ &= 0 \end{aligned}$$

Adulto 31-50

ID {2,4,6,7,9,10}

Acepta: 4 / No Acepta: 2

$$\text{Acepta} = 4/6 = 0,6666 \quad / \quad \text{No Acepta} = 2/6 = 0,3333$$

$$\begin{aligned} H(S, \text{Adulto}) &= - (0,6666 * \log_2(0,6666) + (0,3333 * \log_2(0,3333))) \\ &= - (0,6666 * -0,5851) + (0,3333 * -1,5851) \\ &= - (-0,3900 + -0,5283) \\ &= - (-0,9183) \\ &= 0,9183 \end{aligned}$$

Mayor >50

ID {5}

Acepta Oferta: 1 / No Acepta Oferta: 0

$$\text{Acepta} = 1/1 = 1 \quad / \quad \text{No Acepta} = 0/1 = 0$$

$$H(S, \text{Mayor}) = - (1 * \log_2(1) + (0 * \log_2(0))) = - (1 * 0 + 0) = 0$$

Entropía Ponderada: $H_{ponderada}(S, \text{Edad})$

$$\begin{aligned} &= (3/10 * 0) + (6/10 * 0,9183) + (1/10 * 0) \\ &= 0 + (0,6 * 0,9183) + 0 \\ &= 0,5510 \end{aligned}$$

Ganancia de Información: $IG(S, \text{Edad}) =$

$$IG(S, \text{Edad}) = 1 - 0,5510 = 0,449$$

2.2 Atributo Uso de Datos**Bajo ≤ 3 GB****ID {1,3,8}**

Acepta Oferta: 0 / No Acepta Oferta: 3

Acepta Oferta: $0/3 = 0$ / No Acepta Oferta: $3/3 = 1$

$$\begin{aligned} H(S, \text{Bajo}) &= - (0 * \log_2(0) + (1 * \log_2(1))) \\ &= - (0 + 1 * 0) \\ &= 0 \end{aligned}$$

Medio 3.1 - 6 GB**ID {2,6,7,10}**

Acepta Oferta: 2 / No Acepta Oferta: 2

Acepta Oferta: $2/4 = 0,5$ / No Acepta Oferta: $2/4 = 0,5$

$$\begin{aligned} H(S, \text{Medio}) &= - (0,5 * \log_2(0,5)) + (0,5 * \log_2(0,5)) \\ &= - (0,5 * -1 + 0,5 * -1) \\ &= - (-0,5 + -0,5) \\ &= 1 \end{aligned}$$

Alto > 6 GB**ID {4,5,9}**

Acepta Oferta 3 / No Acepta Oferta: 0

Acepta Oferta: $3/3 = 1$ / No Acepta Oferta: $0/3 = 0$

$$H(S, \text{Alto}) = - (1 * \log_2(1)) + (0 * \log_2(0)) = - (1 * 0 + 0) = 0$$

Entropía Ponderada: $H_{ponderada}(S, \text{Uso de Datos})$

$$\begin{aligned} &= (3/10 * 0) + (4/10 * 1) + (3/10 * 0) \\ &= 0 + 0,4 + 0 \\ &= 0,4 \end{aligned}$$

Ganancia de Información: $IG(S, \text{Uso de Datos})$

$$\begin{aligned} &= 1 - 0,4 \\ &= 0,6 \end{aligned}$$

2.3 Atributo: Tiene Línea Fija

Tiene Línea Fija: 5

ID {2,4,5,7,9}

No Tiene Línea Fija: 5

ID {1,3,6,8,10}

$$p_{Si} = 5/5 = 1$$

$$p_{No} = 5/5 = 1$$

$$\begin{aligned} H(S, \text{Línea FijaSi}) &= - (1 * \log_2(1)) + (1 * \log_2(1)) \\ &= - (1 * 0 + 1 * 0) \\ &= 0 \end{aligned}$$

$$\begin{aligned} H(S, \text{Línea FijaNo}) &= - (1 * \log_2(1)) + (1 * \log_2(1)) \\ &= - (1 * 0 + 1 * 0) \\ &= 0 \end{aligned}$$

Entropía Ponderada: $H_{ponderada}(S, \text{Línea Fija})$

$$H(S, \text{Línea Fija}) = (5/10 * 0) + (5/10 * 0) = 0$$

Ganancia de Información: $IG(S, \text{Línea Fija})$

$$IG(S, \text{Línea Fija}) = 1 - 0 = 1$$

Comparativa de Ganancia de Información

Atributo	Entropía Ponderada	Ganancia de Información (IG)
Tiene Línea Fija	0	1 (Máxima)
Uso de Datos	0,4	0,6
Edad	0,551	0,449

3.Construcción del Árbol de Decisión Paso a Paso

Primero se analiza la impureza y la ganancia de información.

Paso 1.

Analizar la entropía inicial: En conjunto original posee 10 clientes (5 Aceptan promo y 5 No la aceptan), dando una entropía total de 1.

Realizamos una comparativa de la ganancia de información de cada atributo.

- **Tiene Línea Fija** = 1
- **Uso de Datos** = 0,6
- **Edad** = 0,449

Paso 2.

Se elige el nodo raíz.

El atributo con la mayor ganancia de información es "Tiene Línea Fija", la cual tiene un IG (S) de 1.

Paso 3.

Dividir el conjunto de los datos en ramas.

Rama 1: "Tiene Línea Fija" = Si

Clientes incluidos ID {2,4,5,7,9} (5 en Total)

La distribución es (5) Aceptan Promo, (0) No Aceptan Promo

Entropía de cada subconjunto: 0 (subconjunto puro)

Dado que la entropía es cero, no es necesario realizar más divisiones. "Acepto Oferta" Se convierte en un nodo hoja.

Rama 2: "Tiene Línea Fija" = No

Cientes incluidos ID {1,3,6,8,10} 5 en total


La distribución es (0) Aceptan Promo, (5) No Aceptan Promo

Entropía de cada subconjunto: 0 (subconjunto puro)

Dado que la entropía es cero, no se realizan más divisiones. "No Acepta Oferta" Se convierte en un nodo hoja.

Paso 4.

Como la entropía en cada nodo hoja es puro (0), no es necesario seguir dividiendo por lo que el árbol está terminado.



4. Conclusión y ejemplo práctico de aplicación.

El mejor atributo para empezar el árbol es "Tiene Línea Fija". Dado que posee la mayor ganancia de información de todos los atributos con un total de (1), y permite reducir la entropía inicial de (1) a (0) en un solo paso.

Además, clasifica de manera perfecta el total de los datos sin necesidad de evaluar otras variables como la Edad o el Uso de Datos.

La manera más sencilla de utilizar este árbol para predecir si un cliente aceptara la oferta o no sería mediante el uso de dos reglas simples:

- **SI tiene línea fija == "Si" --> Predicción: Aceptara la Oferta.**
- **SI tiene línea fija == "No" --> Predicción: No Aceptara la Oferta.**

Ejemplo:

- Nuevo Cliente A: 25 años, Consume 6.5 GB y tiene línea fija

Evaluación: Tiene Línea Fija? = Si --> Predicción: Aceptara la oferta.

- Nuevo Cliente B: 50 años, Consume 2 GB y No tiene línea fija

Evaluación: Tiene Línea Fija? = No --> Predicción: No aceptara la oferta.